

Propuesta de Investigación: Predicción del tipo de cambio nominal versus la tasa de inflación mensual

Francisco Jesús Guerrero, Juan Pablo Agustín Pedregal, Lucas Andrés Salgado y Fabián Enrique González

Big Data - Maestría en Economía - UdeSa

7 de marzo de 2023



Resumen

El presente trabajo propone intentar predecir cuándo la variación porcentual del tipo de cambio nominal en Argentina (pesos por dolar, calculado a partir de ADRs) supera a la tasa de inflación mensual de dicho país. Para esto se utilizaría una base de datos en serie mensual desde el año 2002 hasta el 2021. Dado esto, creamos una variable binaria que toma valor igual a 1 cuando la variación porcentual del tipo de cambio es mayor a la variación mensual del índice de precios al consumidor. De esta forma, aplicamos diversos modelos propios de la literatura *Big Data* y *machine learning* para predecir esta variable categórica y así evaluar mediante medidas de *accuracy* si estos modelos también son útiles para predecir variables en formato de serie de tiempo.

1. Introducción

Mantener una economía bajo un sendero de crecimiento adecuado no es una tarea sencilla, los actores encargados siempre deben estar pendientes y reaccionar de manera adecuada ante shocks externos e incertidumbre de política interna. Incluso, en algunos casos debe tomar decisiones bajo la presión de regímenes autoritarios que impulsan ciertas políticas fiscales que, si bien pueden responder a demandas sociales, no siempre son las adecuadas para el crecimiento y/o estabilidad económica.

¿Cómo mantenerse en un sendero de crecimiento óptimo? Esta es una pregunta que tiene muchas aristas y es complicado de responder de una manera sencilla. La noción general es que para mantenerse en el sendero se requiere de una coordinación de los agentes económicos de un país para poder impulsar las mejores políticas tanto fiscales como monetarias. Estas medidas dependen de la situación actual así como las expectativas del futuro, por lo cual deben ser políticas que se adapten al contexto, es decir teniendo en consideración variables económicas relevantes.

Las variables a observar se encuentran en constante movimiento, algo que se tiene en cuenta en los modelos macroeconómicos y se observa en la evidencia empírica. Su cantidad se ha incrementado vertiginosamente a lo largo del tiempo, sobre todo en las últimas décadas, respondiendo a la necesidad de caracterizar posibles fenómenos o movimientos inesperado debido a problemas de variables omitidas.

Buenos indicadores macroeconómicos contribuyen en parte al bienestar de la población, por lo que es importante que los hacedores de política los mantengan en niveles óptimos. El hecho de que los agentes encargados no reaccionen adecuadamente ante la situación genera problemas tanto en el corto como en el largo plazo. Por ejemplo, una alta inflación disminuye el poder de compra de los consumidores, si es que no ven aumentados sus ingresos en igual proporción. Si ese es el caso, deberán ajustar la cantidad/calidad de consumo.

Así como la inflación es uno de los indicadores que dan una idea como le va a un país, también se tiene al **tipo de cambio nominal**, el cual indica con cuántas unidades de moneda local se puede adquirir por una moneda internacional (por lo general, se refiere al dólar estadounidense). Países bajo mucha inestabilidad suelen, en promedio, tener alta depreciación anual (o devaluación si tienen el tipo de cambio fijo) y una inflación descontrolada (por ejemplo, Venezuela). Estas grandes depreciaciones suelen disminuir significativamente el valor real de los ahorros de los pequeños ahorristas, que por lo general no tienen acceso al mercado de capitales.

Estos dos indicadores no son aislados entre sí y por lo general se encuentran relacionados a su vez con otros factores, tales como la actividad económica,¹ las reservas internacionales, la cantidad de dinero en la economía, la balanza comercial, la tasa de interés, entre otros. Esto se traduce a que al analizar los datos podríamos observar movimientos conjuntos entre variables.

Para el caso de Argentina, se observa que su política monetaria de mantener una tasa de interés real baja, que tiene el fin de incentivar la inversión productiva no financiera, disminuye la cantidad de ahorro local. Esto está acompañado de un exceso de oferta monetaria, lo que genera una mayor demanda de bienes y divisas extranjeras, presionando el nivel general de precios y el tipo de cambio nominal hacia el alza.

Nuestra propuesta es poner en práctica algoritmos predictivos de *machine learning* que sirvan para la toma de decisiones, tanto de agentes privados como de hacedores

¹Medido con el valor del PBI. En Argentina también se mide mensualmente con el estimador mensual de actividad económica, EMAE

de política. Utilizando datos pasados y presentes, pretendemos indicar si la variación porcentual del tipo de cambio nominal superará en el siguiente mes a la tasa de inflación mensual del país. Esperamos que esta predicción sirva como una ayuda para los agentes que poseen ahorros pero no están interesados en invertir en el mercado de capitales y prefieren operar en mecanismos de ahorro libres de riesgo, o a los encargados de política a tomar medidas para mantener una macroeconomía estable.

El presente documento se ordena de la siguiente forma. Primero, mencionamos literatura relacionada con nuestra propuesta. Segundo, brindamos estadística descriptiva de las variables a utilizar. Tercero, explicamos la metodología para hacer las estimaciones y la predicción. Por último, se concluye y mencionan posibles limitaciones de este trabajo.

2. Literatura relacionada

El problema de predecir agregados es un clásico tema de discusión en Macroeconomía. A lo largo del tiempo, se emplearon diferentes metodologías con el fin de obtener predicciones adecuadas, que constituyan un *input* para la toma de decisiones de agente privados y el gobierno. A grandes razgos, podemos reconocer dos enfoques: el estructural, que consiste en modelar la economía y utilizar esa estructura para predecir; el noestructural, que no supone una parametrización previa, dejando que “hablen los datos” (Diebold, 1998). El uso de *machine learning* entraría en cierta medida en el último enfoque mencionado, pues estos no suponen una estructura. Cabe preguntarse, sin embargo, si estos métodos tienen mejores rendimientos que los tradicionales, lo que justificaría su inclusión en el *toolkit* para predecir variables macroeconómicas.


El uso de las técnicas de *Big Data* en la predicción de variables macroeconómicas y financieras está en constante crecimiento. Kapetanios y Papailias (2018) realizan una revisión de la literatura empírica que aplica novedosas metodologías al *nowcasting*. Estos trabajos explotan la alta frecuencia de datos (mensual, semanal, diaria o incluso por minuto) y nuevas bases para mejorar la calidad de las predicciones. Destacan los que utilizan la cantidad de búsquedas en *Google Trends*, datos de *Twitter* y *web scraping* de precios online. Por ejemplo, Choi y Varian (2009a, 2009b) utilizan datos de búsquedas relacionadas con seguros de desempleo en *Google Trends* para predecir el desempleo. En otra investigación, Cavallo y Rigobon (2016) explotan un gran volumen de precios online (*Billion Prices Project*) para predecir inflación. Para Argentina, Aromí y Llada (2020) aprovechan *tweets* de *Twitter* para crear un indicador de inflación, obteniendo ganancias en *accuracy* en la predicción respecto de métodos tradicionales. Otro trabajo es el de Bianchi *et al.* (2021), quienes aprovechan un enorme volumen de datos y algoritmos de *machine learning* para estimar errores sistemáticos en las expectativas en respuestas a encuestas, encontrando que estos son grandes incluso en profesionales dedicados a predicción. Por último, Lin *et al.* (2006) utilizan un modelo *fuzzy neural network* para predecir la ocurrencia de crisis cambiarias, encontrando que tiene una buena *performance* para ese propósito.

En la literatura de finanzas también es creciente el uso de las técnicas de *Big Data*. Cao *et al.* (2005) utiliza redes neuronales para predecir precios de acciones de firmas chinas, encontrando que estos modelos se desempeñan mejor que los lineales. Zhu *et al.* (2008) muestran que la explotación de un mayor volumen de datos de operaciones puede incrementar la *performance* de las redes neuronales en distintos horizontes de predicción.

3. Estadística descriptiva de la base de datos

En esta sección presentamos brevemente la estadística descriptiva de las variables que entendemos a priori que son relevantes para predecir si el aumento del TCN será mayor que el aumento en el nivel general de precios.

Figura 1: Variación del TCN vs Variación de Precios



Fuente: elaboración propia a partir de datos de INDEC y BCRA.

Tabla 1: Estadísticas descriptivas

	Media	Mediana	Desvío Estandar	Mínimo	Máximo
Variación porcentual del TCN CCL	2.153	0.585	8.199	-16.540	44.628
Inflación Mensual	1.485	0.915	1.248	-.400	6.500
Tasa de interés de los PF a 30 días en Pesos	18.125	14.230	13.708	2.090	76.700
Tasa de interés de los PF a 30 días en USD	0.893	0.610	0.839	0.250	7.620
Reservas internacionales del BCRA	37,838.020	41,871.800	14,190.210	8,986.413	71,662.500
Variación % del nivel de la tasa de empleo	0.143	0.126	0.375	-0.846	1.425
Variación % de M2 en pesos mes a mes	2.325	1.693	4.774	-13.620	19.377
Variación % de M2 en USD mes a mes	5.257	2.306	17.689	-44.715	171.054
TCR bilateral entre el Real brasileño y USD	77.333	72.311	22.014	45.981	153.951
Variación % del TCR bilateral entre el Real y USD	0.111	-0.341	3.989	-10.589	18.984
Cuenta corriente cambiaria en millones de dolares	165.289	426.973	1,154.994	-6,198.220	2,867.790
EMAE con base 2004	135.416	137.452	16.471	90.186	168.886
Exportaciones en millones de dolares	4,879.940	4,917.321	1,453.453	2,024.339	8,393.245
Importaciones en millones de dolares	4,153.318	4,373.750	1,656.971	612.000	7,671.060

Fuente: elaboración propia a partir de datos de INDEC y BCRA.

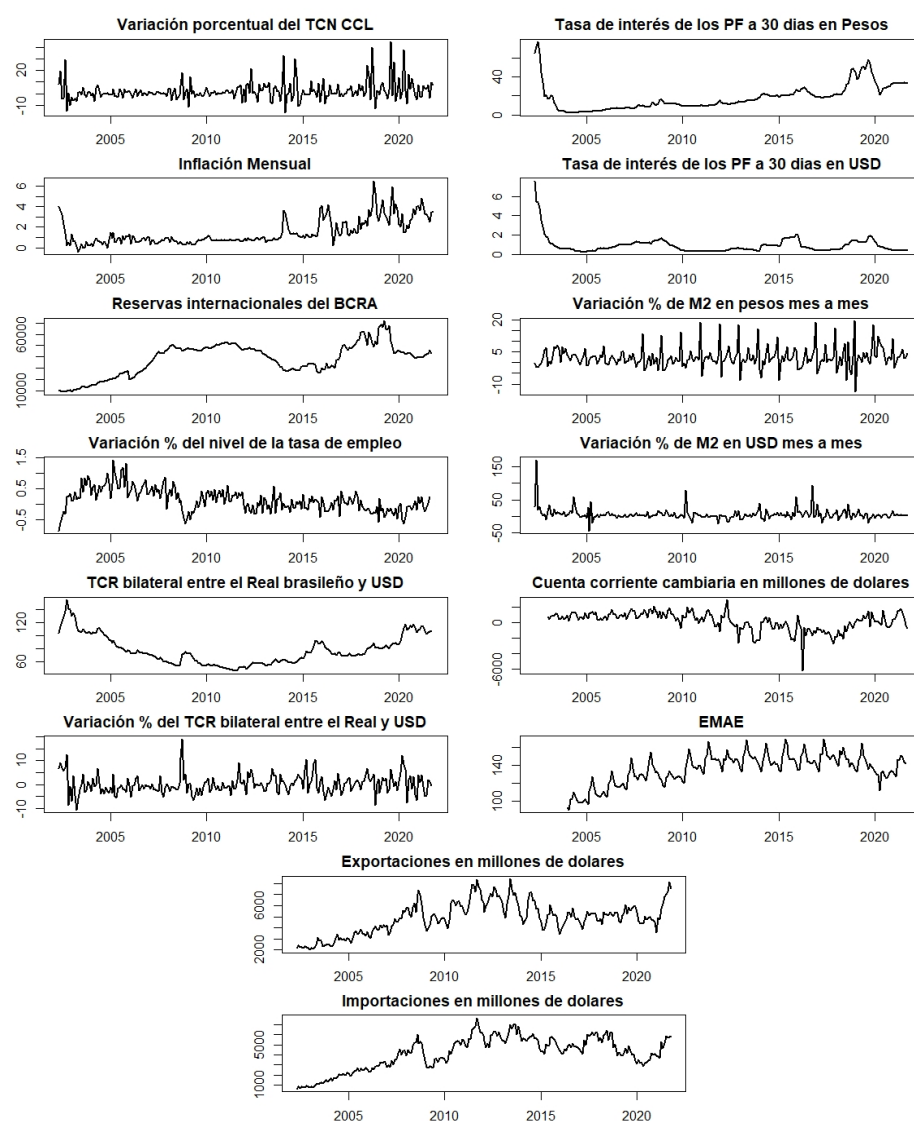
Primero utilizaremos la variación mensual del IPC en puntos porcentuales pues, además de ser un indicador de bienestar de la economía en general, impacta en las decisiones de política monetaria mediante cambios en la tasa de interés.

Así, utilizamos las tasas de interés de los Plazos Fijo a 30 días en pesos y dólares dado que son determinantes para la demanda en pesos y dólares. También las reservas del Banco Central dado que es un instrumento usual para contrarrestar la volatilidad del tipo de cambio pues moderan las expectativas relativas a la inestabilidad cambiaria.

También usaremos el Tipo de Cambio Real del Real brasileño el cual está correlacionado en gran parte porque Argentina y Brasil tienen ambos tipo de cambio flotante, ambos miembros del Mercosur, principales socios comerciales y principales destinos turísticos de sus ciudadanos. Así, Argentina no solo se encuentra afectado por shocks macroeconómicos internacionales similares sino también a los propios brasileños.

Utilizamos variación mensual del IPC en puntos porcentuales debido a que se espera que un aumento en el nivel de precios en la economía este acompañado por

Figura 2: Series de Tiempo



un cambio en las condiciones de cambio internacional. Debido a la gran correlación entre estas variables muchas veces se utilizan ambas para el análisis de la situación económica de un país.

La variable M2 (en pesos y en dólares) mide la oferta de dinero relativamente líquido que existe en la economía. El banco central opera con la oferta de dinero dependiendo de las políticas que se determinen como prioritarias en el mandato y esto termina teniendo fuertes implicancias en el tipo de cambio y la inflación del peso argentino. Otras medidas que reflejan el bienestar general de la economía son importaciones/exportaciones, empleo y nivel de producción. Se entiende que son variables que marcan la performance de un país y por lo tanto pueden tener un rol importante para explicar cambios en el tipo de cambio.

En líneas generales, al ser estas medidas que reflejan la situación económica de un país en distintos aspectos, se espera que haya una capacidad predictiva de las variables explicativas mencionadas, al menos desde un punto de vista teórico. Podemos ver en la figura 2 la evolución de las variables en el tiempo, donde se reflejan los cambios en políticas públicas o condiciones de la economía Argentina

4. Metodología

En primer lugar, como nos interesa saber cuándo el tipo de cambio nominal aumentará más que la inflación, creamos nuestra variable binaria ($Y = 1[\% \Delta e_t > \pi_t]$) que vale 1 si la variación porcentual mensual del tipo de cambio nominal implícito de los ADRs (American Depositary Receipt) es mayor que la tasa de inflación mensual. Y vale 0 en caso contrario.

En segundo lugar, teniendo nuestra matriz de variables explicativas X_t mostradas en la anterior sección, pasamos a estimar varios modelos vistos en clases para luego elegir el que maximice medidas de precisión. A saber, modelo de regresión logística simple, regularizado por LASSO, *Ridge* y *Elastic Net*, K vecinos cercanos, análisis discriminante lineal, *Support vector machine*, modelo de árbol de decisión (CART) elegidos mediante los algoritmos de *Bagging*, *Random Forests* y *Boosting*.

En tercer lugar, teniendo en cuenta que contamos con una base de datos en formato de serie de tiempo, tenemos que decidir la cantidad de rezagos óptimos para hacer las estimaciones y con estas, la predicción. Típicamente, en la literatura clásica de econometría de series de tiempo en modelos multivariados se utilizan los criterios de Akaike, Hannan Quinn, Schwarz o Final Prediction Error. En este trabajo pretendemos que los algoritmos de cada modelo de machine learning elijan cuales variables son necesarias y relevantes para hacer la predicción, proponiendo inicialmente 12 rezagos como máximo. De esta manera, esperaríamos que, por ejemplo, con la regularización por LASSO se descarten los variables rezagadas irrelevantes.

Por último, cabe aclarar que los hiperparámetros serían elegidos por k-fold Cross Validation, con un k a definir pero en principio estaría entre 5 y 10 como aconseja la literatura.

5. Conclusiones y alcance de la investigación

A partir de los nuevos modelo que ofrece *Big Data* planteamos una forma innovadora de responder una pregunta relevante para cualquier inversor argentino conservador, averso al riesgo, de forma directa.

Esperamos que por lo menos uno de nuestros modelos obtenga medidas de *accuracy* aceptables para lograr predecir si resulta más beneficios en promedio para los ahorristas invertir en un plazo fijo indexado por CER (índice que se ajusta según la inflación) o comprar dolares a partir de información pública y de fácil acceso.

Las limitaciones que podríamos llegar a tener es que los modelos pierdan potencia predictiva si no encontramos una serie de datos suficientemente grande.

Referencias

- Aromí, J. D. y Llada, M. (2020). Forecasting Inflation with Twitter. *Anales de la Asociación Argentina de Economía Política*.
- Bianchi, F., Ludvigson, S. C. y Ma, S. (2021). Belief Distortions and Macroeconomic Fluctuations. *NBER Working Paper 27406*.
- Cao, Q., Laggio, K. B. y Shniederjans, M. J. (2005). A Comparison between Fama and French's Model and Artificial Neural Networks in Predicting the Chinese Stock Market. *Computers & Operations Research*, 32, 2499-2152.
- Cavallo, A. y Rigobon, R. (2016). The Billion Prices Project: Using Online Prices for Measurement and Research. *Journal of Economic Perspectives*, 30(2), 151-178.
- Choi, H. y Varian, H. (2009a). Predictin Initial Claims for Inemployment Benefits. *Google Technical Report*.
- Choi, H. y Varian, H. (2009b). Predicting the Present with Google Trends. *Google Technical Report*.
- Diebold, F. X. (1998). The Past, Present and Future of Macroeconomic Forecasting. *Journal of Economic Perspectives*, 12(2), 175-192.
- Kapetanios, G. y Papailias, F. (2018). Big Data & Macroeconomic Nowcasting: Methodological Review. *Discussion Papers from Economic Statistics Centre of Excellence ESCoE DP-2018-12*.
- Lin, C.-S., Khan, H. A., Wang, Y.-C. y Chang, R.-Y. (2006). A New Approach to Modeling Early Warning Systems for Currency Crises: can a Machine Learning Fuzzy Expert System Predict the Currency Crises Effectively? *CARF Working Paper*.
- Zhu, X., Wang, H., Xu, L. y Li, H. (2008). Predicting Stock Index Increments by Neural Networks: The Role of Trading Volume under Different Horizons. *Expert Systems with Applications*, 34, 3043-3054.